

Universidade de São Paulo
Instituto de Ciências Matemáticas e de Computação
SME - Departamento de Matemática Aplicada e Estatística

**Relatório:
Otimização de Problema de
Escalonamento de Atividades
Acadêmicas**

Docente responsável: Prof. Dr. Marcos Mansano Furlan

Bianca Duarte Batista Lacerda - 15443221
Lucas Soares Leite Santos - 15472162
Murilo de Lima Mariano - 15480898
Pedro Luis de Alencar Ribeiro - 15590852
Vinicius Reis Gonçalves - 15491921

São Carlos
2026

Universidade de São Paulo
Instituto de Ciências Matemáticas e de Computação
SME - Departamento de Matemática Aplicada e Estatística

**Relatório:
Otimização de Problema de
Escalonamento de Atividades
Acadêmicas**

Relatório do 1º trabalho prático da disciplina **SME 0610 - Programação Matemática**, do curso de Engenharia de Computação (EESC/ICMC - USP), utilizando *solvers* comercial e livre, além da implementação de um método alternativo.

Docente responsável: Prof. Dr. Marcos Mansano Furlan.

Bianca Duarte Batista Lacerda - 15443221

Lucas Soares Leite Santos - 15472162

Murilo de Lima Mariano - 15480898

Pedro Luis de Alencar Ribeiro - 15590852

Vinicius Reis Gonçalves - 15491921

São Carlos
2026

Sumário

1	INTRODUÇÃO	1
2	MODELAGEM MATEMÁTICA	3
3	SOLUÇÕES OBTIDAS	7
3.1	<i>SOLVER</i> COMERCIAL (Gurobi)	7
3.2	<i>SOLVER</i> LIVRE (SCIP)	11
3.2.1	INSTÂNCIAS AMPLIADAS	13
3.3	MÉTODO ALTERNATIVO	16
4	CONCLUSÃO	19
	REFERÊNCIAS BIBLIOGRÁFICAS	21

1 INTRODUÇÃO

O Problema de Calendário de Provas (*Exam Timetabling Problem* - ETP) consiste na alocação de exames acadêmicos em períodos de tempo disponíveis, de modo a satisfazer restrições institucionais e minimizar conflitos e inconvenientes para os estudantes. Esse problema está inserido na classe dos problemas de escalonamento (*timetabling*), amplamente estudados na área de Pesquisa Operacional e Otimização Combinatória devido à sua elevada complexidade computacional e grande aplicabilidade prática em instituições de ensino, empresas e, até mesmo, sistemas logísticos.

Tendo isso em vista, nota-se que a elaboração manual de calendários de provas é uma tarefa complexa e sujeita a erros, especialmente no contexto universitário com grande número de disciplinas e estudantes matriculados simultaneamente em diferentes cursos. Em muitos casos, a verificação de conflitos entre provas já representa, por si só, um grande desafio, uma vez que um mesmo aluno pode estar matriculado em diferentes disciplinas. Além disso, mesmo quando não há conflitos diretos de horário, a proximidade excessiva entre exames pode causar sobrecarga aos estudantes, reduzindo o desempenho e comprometendo a qualidade do processo avaliativo.

Nesse sentido, torna-se necessário o desenvolvimento de modelos matemáticos capazes de automatizar e otimizar o processo de construção de calendários acadêmicos. Sob tal escopo, técnicas de **Programação Linear Inteira** e **Programação Inteira Mista** têm sido amplamente utilizadas para modelar problemas de escalonamento, permitindo representar formalmente restrições institucionais e critérios de qualidade da solução.

Para melhores efeitos de contextualização, o ETP pertence à classe dos problemas ditos **NP-difíceis**. Tais problemas apoiam-se na ideia de que o esforço computacional necessário para encontrar soluções ótimas cresce muito rapidamente conforme o tamanho de sua instância aumenta. Por esse motivo, diversos trabalhos da literatura propõem tanto métodos exatos quanto heurísticas e metaheurísticas para sua resolução. Os métodos exatos garantem a obtenção da solução ótima; não obstante, podem apresentar elevado custo computacional em instâncias de grande porte. Por outro lado, heurísticas e metaheurísticas buscam obter soluções de boa qualidade em menores tempos computacionais.

Segundo Carter e Laporte (1996), o problema de escalonamento de exames tornou-se uma importante área de pesquisa em virtude de sua relevância prática e diversidade de restrições encontradas em instituições do mundo real. De acordo, também, com Burke e Petrovic (2002) problemas de *timetabling* envolvem, frequentemente, objetivos conflitantes, fato que exige abordagens

flexíveis capazes de equilibrar qualidade da solução e eficiência computacional. Esses são apenas alguns exemplos de trabalhos acadêmicos encontrados na literatura, o que evidencia a importância e a pertinência de seus estudos nas mais diversas aplicações.

Dessa forma, é desenvolvido, no presente trabalho, um modelo de **Programação Linear Inteira Binária** para o ETP, considerando restrições de conflito entre disciplinas e um critério (peso) de minimização da proximidade entre exames realizados pelos mesmos estudantes. Nesta aplicação em questão, a fim de viabilizar a resolução por *solvers* lineares, os termos quadráticos presentes na função objetivo foram linearizados por meio de novas restrições e variáveis auxiliares.

Outrossim, seguindo as especificações, para além da solução exata via *solvers* (tanto o comercial quanto o livre), foi proposta uma abordagem alternativa baseada em heurística, com o intuito de comparar desempenho computacional e qualidade das soluções obtidas. Assim, pode-se analisar as vantagens e limitações das diferentes estratégias de resolução.

2 MODELAGEM MATEMÁTICA

Uma vez apresentado o problema, é possível, então, realizar sua modelagem matemática. Para tanto, foram definidas as especificidades a serem consideradas.

Novamente, vale salientar que é desejado construir um calendário de provas para uma universidade, alocando cada prova em um horário disponível, de modo que:

- nenhum aluno tenha duas provas simultâneas;
- as provas de um mesmo aluno fiquem o mais espaçadas possível;
- a distribuição de provas seja adequada.

O objetivo do modelo é minimizar penalizações associadas à proximidade entre provas realizadas pelos mesmos alunos.

Sendo assim, definem-se os conjuntos:

- $A = \{1, 2, \dots, p\}$ o conjunto de alunos, em que cada elemento representa um estudante;
- $E = \{1, 2, \dots, n\}$ o conjunto de provas de uma disciplina, em que cada elemento representa uma prova/disciplina;
- $T = \{1, 2, \dots, m\}$ o conjunto de horários disponíveis, em que cada elemento representa um possível período de aplicação de prova.

Para os parâmetros, pode-se definir uma matriz de conflito e atribuir uma penalidade (peso) para duas provas conflitantes. Além disso, é importante mensurar a distância temporal entre *slots* disponíveis para a realização de um exame. Desse modo, tem-se:

- $r_{ia} \in \{0, 1\}$ vale 1 se o aluno a estiver matriculado na disciplina da prova i ;
- c_{ij} a matriz que representa o número de alunos matriculados, ao mesmo tempo, nas provas i e j ;
- $w_{tt'}$ a penalidade associada à distância entre os horários t e t' .

A caráter de exemplo, é possível imaginar a seguinte correlação:

Tabela 1: Exemplificação de penalidades em função da distância entre provas.

Distância	Penalidade
1 horário	10
2 horários	5
3 horários	1
Maior	0

Fonte: Dos próprios autores.

Já para as variáveis de decisão, define-se:

$$x_{it} = \begin{cases} 1, & \text{se a prova } i \text{ ocorre no horário } t \\ 0, & \text{caso contrário} \end{cases}$$

Além disso, é de interesse linearizar o produto $x_{it}x_{jt'}$. Logo, define-se a variável auxiliar $y_{ijtt'}$ como produto de variáveis binárias:

$$y_{ijtt'} = \begin{cases} 1, & \text{se } x_{it} = 1 \text{ e } x_{jt'} = 1 \\ 0, & \text{caso contrário} \end{cases}$$

A função objetivo consiste em minimizar a soma das penalizações causadas pela proximidade entre provas de alunos em comum. Em representação matemática:

$$\min \sum_{\substack{i, j \in E \\ i < j}} \sum_{t \in T} \sum_{t' \in T} c_{ij} w_{tt'} y_{ijtt'}$$

em que $c_{ij} = \sum_{a \in A} r_{ia} r_{ja}$ é a matriz de conflito.

Dessa maneira, a função objetivo percorre todos os pares de provas, verifica quantos alunos possuem ambas as provas e aplica penalidade conforme a proximidade entre os horários escolhidos.

Finalmente, para as restrições, tem-se:

1. Cada prova deve ocorrer apenas 1 (uma) vez

$$\sum_{t \in T} x_{it} = 1, \forall i \in E$$

Interpreta-se que cada prova deve ser alocada em exatamente um horário. Ela se faz necessária pois, na sua ausência, uma prova poderia não ser marcada ou poderia ser marcada em múltiplos horários simultaneamente.

2. Provas conflitantes não podem ocorrer simultaneamente

$$x_{it} + x_{jt} \leq 1, \forall i, j \in E, i < j : c_{ij} > 0, \forall t \in T$$

Interpreta-se que, se duas provas possuem alunos em comum, elas não podem ocorrer no mesmo horário. Faz-se necessária, no contexto, uma vez que elimina conflitos diretos de calendário para os estudantes.

3. Linearização do produto de variáveis binárias

$$y_{ijtt'} \leq x_{it}, \forall i < j, \forall t, t' \in T$$

A variável auxiliar só pode valer 1 se $x_{it} = 1$

$$y_{ijtt'} \leq x_{jt'}, \forall i < j, \forall t, t' \in T \text{ (limite superior)}$$

A variável auxiliar também depende de $x_{jt'} = 1$

$$y_{ijtt'} \geq x_{it} + x_{jt'} - 1, \forall i < j, \forall t, t' \in T \text{ (limite inferior)}$$

A restrição força $y_{ijtt'} = 1$ quando $x_{it} = 1$ e $x_{jt'} = 1$

Desse modo, são cobertos todos os possíveis casos:

Tabela 2: Relações entre as variáveis de decisão e auxiliar para linearização.

x_{it}	$x_{jt'}$	$y_{ijtt'}$
0	0	0
0	1	0
1	0	0
1	1	1

Fonte: Dos próprios autores.

4. Domínio

$$x_{it} \in \{0, 1\}$$

$$y_{ijtt'} \in \{0, 1\}$$

Portanto, resumidamente, tem-se a modelagem matemática completa como:

Modelagem Matemática - ETP

$$\min \sum_{\substack{i, j \in E \\ i < j}} \sum_{t \in T} \sum_{t' \in T} c_{ij} w_{tt'} y_{ijtt'}$$

sujeito a

$$\begin{aligned} \sum_{t \in T} x_{it} &= 1, \forall i \in E \\ x_{it} + x_{jt} &\leq 1, \forall i, j \in E, i < j : c_{ij} > 0, \forall t \in T \\ y_{ijtt'} &\leq x_{it}, \forall i < j, \forall t, t' \in T \\ y_{ijtt'} &\leq x_{jt'}, \forall i < j, \forall t, t' \in T \\ y_{ijtt'} &\geq x_{it} + x_{jt'} - 1, \forall i < j, \forall t, t' \in T \\ x_{it} &\in \{0, 1\} \\ y_{ijtt'} &\in \{0, 1\} \end{aligned}$$

Por fim, apenas para fins computacionais, vale salientar que a complexidade do modelo abordado no presente trabalho é tal que:

$$|E||T| \text{ (com as variáveis principais)}$$

e

$$\frac{|E|(|E| - 1)}{2} |T|^2 \text{ (com as variáveis auxiliares),}$$

fator que indica o crescimento quadrático no número de exames e horários. O modelo, portanto, pode se tornar computacionalmente caro para instâncias grandes, o que justifica o uso de heurísticas/metaheurísticas e a comparação entre métodos alternativos de resolução.

3 SOLUÇÕES OBTIDAS

3.1 *SOLVER* COMERCIAL (Gurobi)

Antes de apresentar os resultados, convém esclarecer a estratégia adotada para garantir a comparabilidade entre as duas vias de resolução exata empregadas neste trabalho. Tanto para o *solver* comercial (**Gurobi**) quanto para o *solver* livre (**SCIP**), partiu-se de um mesmo modelo e de uma mesma estrutura de código, adaptando-se apenas a interface de programação própria de cada ferramenta. Dessa forma, as variáveis de decisão, as restrições e a função objetivo permanecem idênticas nas duas implementações, residindo a única diferença efetiva na biblioteca utilizada para construir e resolver o modelo (**gurobipy**, no caso do **Gurobi**; e **PySCIP0pt**, no caso do **SCIP**). Ademais, as duas execuções foram submetidas exatamente à mesma instância de teste, com os mesmos alunos, as mesmas disciplinas e os mesmos horários disponíveis. Tal cuidado metodológico isola o *solver* como única variável do experimento, de modo que eventuais diferenças de tempo de execução, número de nós explorados ou, até mesmo, qualidade da solução possam ser atribuídas apenas ao *solver* em si, e não a discrepâncias de modelagem.

O **Gurobi** é um *solver* comercial de otimização matemática, com suporte à **Programação Linear**, **Inteira** e **Inteira Mista**. Para o presente trabalho, utilizou-se a versão 13.0.2, sob licença acadêmica (**WLS**), de uso não comercial, vinculada a uma conta institucional.

A implementação computacional reproduz fielmente a formulação descrita na seção anterior. As variáveis binárias principais x_{it} foram criadas para cada par disciplina-horário, totalizando

$$|E| \cdot |T| = 7 \cdot 10 = 70 \text{ variáveis.}$$

As variáveis auxiliares $y_{ijt'}$, responsáveis pela linearização do produto $x_{it} x_{jt'}$, foram instanciadas apenas para pares de provas distintas $i < j$ e horários distintos $t \neq t'$, perfazendo uma soma de 1890 variáveis. Optou-se por descartar os termos com $t = t'$ na construção das auxiliares, uma vez que a coincidência de horários entre provas conflitantes já é proibida pela restrição de conflito, tornando desnecessária a penalização correspondente. Assim, o modelo final conta com 1960 variáveis binárias e 5887 restrições.

As restrições foram codificadas em correspondência direta com o modelo: a alocação única de cada prova, a proibição de provas conflitantes no mesmo horário e o conjunto de três desigualdades de linearização para cada variável auxiliar. A função objetivo, por sua vez, percorre todos os pares de provas e horários, ponderando cada variável auxiliar pelo produto entre a matriz de

conflito c_{ij} e a penalidade de proximidade $w_{tt'}$. Por fim, estabeleceu-se um limite de tempo de 300 segundos para a execução, de modo a uniformizar o critério de parada entre os dois *solvers*.

A instância de teste foi construída de maneira fixa, a fim de assegurar a reprodutibilidade dos experimentos. Consideraram-se sete disciplinas, a saber:

- Circuitos Eletrônicos 1;
- Fundamentos de Controle;
- Ondas Eletromagnéticas;
- Programação Matemática;
- Estatística 1;
- Processamento Digital de Sinais;
- Sistemas Operacionais 1.

Tais disciplinas foram alocadas em dez horários distribuídos ao longo de uma semana, em períodos matutino e vespertino, de segunda à sexta-feira (08h/14h). A turma é composta por vinte alunos, cada qual matriculado em três matérias.

A partir das matrículas, a matriz de conflito c_{ij} foi obtida computacionalmente pela contagem de alunos comuns a cada par de provas. Vale destacar que, nesta instância, todos os vinte e um pares possíveis de disciplinas compartilham ao menos um aluno, de modo que a restrição de conflito, por si só, já força a alocação de cada prova em um horário distinto. A matriz de penalidades $w_{tt'}$ seguiu o padrão decrescente apresentado anteriormente, atribuindo punições mais severas a provas próximas no tempo e nenhuma punição a provas separadas por mais de três horários.

O **Gurobi** resolveu a instância até a otimalidade comprovada, alcançando valor de função objetivo igual a 97,0, com *gap* de 0,00% e tempo de execução de aproximadamente 1,57 segundo, valor muito inferior ao limite de 300 segundos estabelecido. O solver partiu de uma solução heurística inicial de valor 170 e refinou-a sucessivamente, passando por incumbentes de 152, 116, 111, 108, 105 e 100, até atingir o ótimo de 97. A relaxação linear na raiz forneceu limitante inferior nulo, o que evidencia a fragilidade da relaxação contínua para este tipo de formulação e a consequente necessidade de ramificação. Foram explorados 4125 nós da árvore de busca, com auxílio de diversos planos de corte (**Gomory**, **MIR**, **Zero-half**, **RLT** e **BQP**), sendo

os cortes **RLT** particularmente numerosos, fato coerente com a natureza do produto linearizado entre variáveis binárias.

Abaixo, as tabelas esboçam os resultados obtidos.

Tabela 3: Calendário ótimo obtido pelo solver **Gurobi**.

Disciplina	Horário
Sistemas Operacionais 1	Segunda 08h
Processamento Digital de Sinais	Segunda 14h
Estatística 1	Terça 14h
Fundamentos de Controle	Quarta 14h
Ondas Eletromagnéticas	Quinta 08h
Circuitos Eletrônicos 1	Sexta 08h
Programação Matemática	Sexta 14h

Fonte: Dos próprios autores.

Tabela 4: Síntese dos resultados do solver **Gurobi**.

Métrica	Valor
Valor da função objetivo	97,0
<i>Gap</i> de otimalidade	0,00%
Tempo de execução	1,57 s
Número de variáveis	1960
Número de restrições	5887
Nós explorados	4125

Fonte: Dos próprios autores.

O calendário ótimo aloca as sete provas em horários distintos e bem espaçados, conforme esperado diante do elevado grau de conflito da instância. O valor da função objetivo, igual a 97, representa a penalização mínima de proximidade alcançável para esta configuração, restando como resíduo inevitável, dado o número limitado de horários frente à quantidade de provas mutuamente conflitantes.

Por fim, cumpre observar que, embora o ETP pertença à classe dos problemas **NP-difíceis**, a instância considerada é de pequeno porte, o que explica a resolução praticamente instantânea. À medida que o número de provas e horários cresce, o crescimento quadrático no número de variáveis auxiliares tende a elevar substancialmente o custo computacional, fato que justifica a posterior comparação com o *solver* livre e com a abordagem heurística. Os

resultados aqui obtidos servem, acima de tudo, como referência ótima (valor 97) para aferir a qualidade das soluções produzidas pelas demais estratégias.

3.2 *SOLVER* LIVRE (SCIP)

O SCIP (*Solving Constraint Integer Programs*), por sua vez, é um *framework* de otimização de código aberto desenvolvido originalmente pelo **Instituto Zuse de Berlim** (ZIB), reconhecido como um dos *solvers* livres de maior desempenho para problemas de **Programação Inteira Mista**. Diferentemente de *solvers* comerciais, o SCIP disponibiliza acesso integral ao seu código-fonte e adota uma arquitetura modular, permitindo a customização de estratégias de **branch-and-bound**, **geração de cortes** e **heurísticas internas**. Conforme supracitado, a implementação sob essa segunda óptica reproduz fielmente a formulação da seção anterior (**Gurobi**). As variáveis binárias principais x_{it} foram criadas para cada par disciplina-horário, totalizando, de modo análogo,

$$|E| \cdot |T| = 7 \cdot 10 = 70 \text{ variáveis.}$$

As variáveis auxiliares $y_{ijtt'}$, responsáveis pela linearização do produto $x_{it}x_{jt'}$, foram instanciadas apenas para pares de provas e horários distintas, isto é, $i < j$ e $t \neq t'$. Tais fatores, agora, perfizeram um total de 1960 variáveis binárias.

No que tange ao número de restrições, o modelo apresentou 3217 restrições, valor inferior ao registrado pelo **Gurobi** (5887) para a mesma formulação. Essa divergência não indica diferença de modelagem, mas sim uma distinção na forma como cada biblioteca contabiliza internamente os limites de domínio das variáveis binárias. À medida que o **PySCIPOpt**, por exemplo, os absorve na estrutura interna do *solver*, sem expô-los como restrições explícitas no contador retornado por `getNConss()`, o **Gurobi** os inclui em sua contagem. Do ponto de vista matemático, contudo, as duas implementações são estritamente equivalentes.

A instância de teste utilizada é a mesma descrita anteriormente, ou seja, sete disciplinas, dez horários distribuídos ao longo da semana em períodos matutino e vespertino, e vinte alunos, cada qual matriculado em três disciplinas. O limite de tempo de execução foi igualmente fixado em 300 segundos.

Ao contrário do **Gurobi**, que convergiu em aproximadamente 1,57 segundo, o SCIP demandou cerca de 246 segundos para atingir a otimalidade, tendo explorado 4744 nós da árvore de **branch-and-bound** ao longo de 368 soluções incumbentes até confirmar otimalidade. Essa trajetória de convergência mais lenta reflete características estruturais do *solver* SCIP: enquanto o **Gurobi** se beneficia de décadas de engenharia proprietária em seu **branch-and-cut** (como estratégias altamente refinadas de seleção de variáveis de ramificação, geração agressiva de planos de corte e heurísticas primais sofisticadas), o SCIP apresenta desempenho geralmente inferior em

instâncias de **Programação Inteira Binária** densamente conectadas, como é o caso do ETP com alto grau de conflito.

A seguir, as tabelas sintetizam os resultados obtidos nessa etapa.

Tabela 5: Calendário ótimo obtido pelo solver **SCIP**.

Disciplina	Horário
Sistemas Operacionais 1	Segunda 08h
Processamento Digital de Sinais	Segunda 14h
Estatística 1	Terça 14h
Fundamentos de Controle	Quarta 14h
Ondas Eletromagnéticas	Quinta 08h
Circuitos Eletrônicos 1	Sexta 08h
Programação Matemática	Sexta 14h

Fonte: Dos próprios autores.

Tabela 6: Síntese dos resultados do solver **SCIP**.

Métrica	Valor
Valor da função objetivo	97,0
<i>Gap</i> de otimalidade	0,00%
Tempo de execução	246 s
Número de variáveis	1960
Número de restrições	3217
Nós explorados	4744

Fonte: Dos próprios autores.

Dessa maneira, vê-se que, para essa instância, o calendário ótimo produzido pelo **SCIP** é idêntico ao obtido pelo **Gurobi**, o que atesta tanto a equivalência das implementações quanto a consistência da modelagem adotada. O valor da função objetivo (97) representa a penalização mínima de proximidade alcançável para esta configuração.

Embora a diferença de tempo entre os dois *solvers* seja expressiva, cabe ressaltar que o **SCIP**, apesar de gratuito e com *features* menos sofisticadas, cumpriu seu papel, encontrando a solução ótima dentro do limite proposto de 300 segundos. Para instâncias de pequeno porte, como aqui considerada, essa diferença de desempenho, embora relevante do ponto de vista técnico, não compromete a viabilidade prática do *solver* livre.

3.2.1 INSTÂNCIAS AMPLIADAS

Adicional e comparativamente, com o fito de ilustrar o comportamento do modelo frente ao crescimento da instância, fez-se um experimento com configurações randômicas: uma mais e outra menos restritiva.

Para a primeira, mantiveram-se as mesmas sete disciplinas; entretanto, reduziu-se o número de horários disponíveis de dez para cinco (segunda à quarta-feira, nos períodos matutino e vespertino) e ampliou-se a turma para cinquenta alunos, cada qual matriculado em quatro a seis disciplinas, geradas aleatoriamente.

Nessa configuração, o SCIP retornou *status* **infectível** em 0,56 segundos, explorando apenas 1 nó da árvore de **branch-and-bound**. A infectibilidade foi detectada já na raiz, sem necessidade de ramificação, pois a restrição de conflito (**R2**) exige que cada par de provas com alunos em comum ocupe horários distintos. Com cinquenta alunos matriculados em quatro a seis disciplinas cada, a probabilidade de que todos os vinte e um pares de disciplinas compartilhem ao menos um aluno é muito elevada. Consequentemente, o modelo requer que as sete provas sejam alocadas em sete horários distintos; porém, com apenas cinco períodos disponíveis, essa condição se torna impossível, e o problema não admite solução viável.

Tabela 7: Síntese dos resultados da primeira instância ampliada (SCIP).

Métrica	Valor
Status	Infectível
Tempo de execução	0,56 s
Nós explorados	1
Número de variáveis	455
Número de restrições	620

Fonte: Dos próprios autores.

Esse resultado evidencia uma propriedade fundamental dos problemas de escalonamento: a factibilidade do modelo depende criticamente da relação entre o número de entidades a alocar e os recursos disponíveis. Como dito, no ETP, quando o grau de conflito da instância é alto, o número de horários disponíveis torna-se o fator limitante da existência de qualquer solução viável, independentemente da qualidade da otimização empregada.

A segunda abordagem, por sua vez, foi bem semelhante: as mesmas sete disciplinas e os mesmos cinco horários. A diferença, agora, residia na quantidade de alunos e de disciplinas em que cada estudante estava matriculado: 20 pupilos cursando entre duas e três matérias, geradas aleatoriamente.

Nesse caso, o **SCIP** confirmou a otimalidade em 4 segundos, explorando 23 nós da árvore de **branch-and-bound** e percorrendo 16 soluções incumbentes. O valor da função objetivo alcançado foi de 182,0, com *gap* de 0,00%. O modelo contou com 455 variáveis binárias e 339 restrições.

Tabela 8: Matriz de conflitos da instância intermediária.

Par de disciplinas	Alunos em comum
Circuitos Eletrônicos 1 × Fundamentos de Controle	3
Circuitos Eletrônicos 1 × Programação Matemática	3
Circuitos Eletrônicos 1 × Estatística 1	1
Circuitos Eletrônicos 1 × Processamento Digital de Sinais	1
Circuitos Eletrônicos 1 × Sistemas Operacionais 1	4
Fundamentos de Controle × Ondas Eletromagnéticas	1
Fundamentos de Controle × Programação Matemática	1
Fundamentos de Controle × Estatística 1	4
Fundamentos de Controle × Processamento Digital de Sinais	2
Fundamentos de Controle × Sistemas Operacionais 1	4
Ondas Eletromagnéticas × Programação Matemática	1
Ondas Eletromagnéticas × Sistemas Operacionais 1	4
Programação Matemática × Estatística 1	2
Programação Matemática × Sistemas Operacionais 1	2
Estatística 1 × Processamento Digital de Sinais	1
Estatística 1 × Sistemas Operacionais 1	1
Processamento Digital de Sinais × Sistemas Operacionais 1	3

Fonte: Dos próprios autores.

Além disso, o calendário ótimo obtido é apresentado na Tabela 9. Observa-se que dois pares de disciplinas foram alocados no mesmo horário: **Circuitos Eletrônicos 1** e **Ondas Eletromagnéticas**, ambas na Terça 08h; e **Programação Matemática** e **Processamento Digital de Sinais**, ambas na Quarta 08h. Essa alocação, embora à primeira vista possa sugerir conflito e estranheza, é inteiramente válida: nenhum desses dois pares figura na matriz de conflitos, ou seja, não há alunos matriculados simultaneamente nas duas disciplinas de cada par. A restrição (**R2**) proíbe, apenas, a coincidência de horários entre pares *conflitantes* ($c_{ij} > 0$). Para pares sem alunos em comum, o modelo é livre para alocá-los no mesmo período, fator utilizado pelo *solver* para minimizar a penalização global.

Tabela 9: Calendário ótimo da instância intermediária (SCIP).

Disciplina	Horário
Sistemas Operacionais 1	Segunda 08h
Estatística 1	Segunda 14h
Circuitos Eletrônicos 1	Terça 08h
Ondas Eletromagnéticas	Terça 08h
Fundamentos de Controle	Terça 14h
Programação Matemática	Quarta 08h
Processamento Digital de Sinais	Quarta 08h

Fonte: Dos próprios autores.

Tabela 10: Síntese dos resultados da instância intermediária (SCIP).

Métrica	Valor
Valor da função objetivo	182,0
Gap de otimalidade	0,00%
Tempo de execução	4,0 s
Nós explorados	23
Soluções incumbentes	16
Número de variáveis	455
Número de restrições	339

Fonte: Dos próprios autores.

Nota-se, portanto, que o valor da função objetivo desta instância (182,0) é sensivelmente superior ao obtido na instância principal (97,0). Esse resultado é esperado: com apenas cinco horários disponíveis e dezessete pares conflitantes, as provas ficam necessariamente mais concentradas ao longo da semana, aumentando a penalização por proximidade.

A comparação entre as três instâncias testadas - a principal (factível, por ambos os *solvers*, ótimo 97,0), a intermediária (factível, ótimo 182,0) e a ampliada (infactível) - ilustra, de forma clara, como a relação entre o número de horários disponíveis, o tamanho da turma e a sobreposição de matrículas determina não apenas a qualidade da solução, mas principalmente a própria existência de um calendário viável.

Nesse cenário, portanto, a detecção eficiente de factibilidade/infactibilidade pelo *solver* é, em si, um resultado relevante, pois sinaliza ao gestor acadêmico a necessidade de ampliar a grade de horários antes mesmo de se buscar uma solução ótima.

3.3 MÉTODO ALTERNATIVO

O método alternativo proposto utiliza a metaheurística *Simulated Annealing* (SA) para contornar a complexidade computacional inerente aos problemas de agendamento (*timetabling*). Diferente dos métodos exatos, que exploram exaustivamente o espaço de busca, o SA simula o processo térmico de resfriamento de metais para navegar por soluções viáveis, permitindo a aceitação temporária de movimentos que aumentam o custo do sistema. Essa característica é fundamental para que o algoritmo escape de ótimos locais, permitindo encontrar calendários de provas altamente eficientes em uma fração do tempo que um *solver* tradicional levaria para atingir a convergência. Dessa forma, a metaheurística se prova muito eficiente mesmo que aceite resultados piores ou ainda não encontre a otimalidade do problema, mas encontre uma solução satisfatória, dentro das expectativas e proporções do problema em um tempo de execução curto (se comparado aos métodos exatos quando implementados computacionalmente).

A implementação, aqui, foca na flexibilidade da função objetivo, que integra tanto as restrições rígidas quanto as penalidades por proximidade de exames para o mesmo corpo discente. Ao ajustar parâmetros como a temperatura inicial e o fator de resfriamento, o algoritmo consegue equilibrar a exploração de novos cenários com a intensificação da busca em regiões promissoras do espaço de soluções, mantendo ainda um tempo de execução satisfatório, mesmo com problemas mais complexos. Como resultado, o método entrega um cronograma que respeita a disponibilidade física das salas e minimiza o desgaste dos alunos, apresentando-se como uma ferramenta robusta e escalável para a gestão acadêmica.

A implementação, tal qual nos outros métodos, seguiu um modelo padrão, para fins de comparabilidade dos resultados, contendo as mesmas disciplinas, os mesmos conjuntos de horários e o mesmo número de alunos realizando cada avaliação. A metaheurística demanda uma solução inicial, para que possa, a partir dela, gerar soluções vizinhas e, assim, explorar o espaço de soluções. A solução inicial escolhida para as entradas padrão foi:

Tabela 11: Solução inicial da metaheurística implementada.

Disciplina	Horário
Circuitos Eletrônicos I	Segunda 14h
Fundamentos de Controle	Terça 08h
Ondas Eletromagnéticas	Terça 14h
Programação Matemática	Quarta 08h
Estatística 1	Quarta 14h
Processamento Digital de Sinais	Quinta 08h
Sistemas Operacionais 1	Quinta 14h

Fonte: Dos próprios autores.

Executou-se, então, o algoritmo 4 vezes, variando o coeficiente de resfriamento α . A temperatura de início se manteve inalterada $T_{start} = 1000$, tal como a temperatura final $T_{end} = 0.1$. Os resultados obtidos das respectivas execuções foram dispostos na tabela abaixo. Vale ressaltar, ainda, que os valores alocados como **custo da solução** foram os mais recorrentes dentro de 30 execuções do algoritmo, dado que a aleatoriedade da escolha das soluções faz com que haja uma certa dispersão entre os resultados finais quanto menor α .

Tabela 12: Resultados obtidos pelo método alternativo.

α	Soluções exploradas	Tempo de execução (s)	Custo da solução
0.9	88	0.008	138
0.99	917	0.008	113
0.999	9206	0.075	108
0.9999	92099	0.76	97
0.99999	921030	7.63	97

Fonte: Dos próprios autores.

É evidente que, quanto mais próximo de 1 o coeficiente de resfriamento, mais soluções são exploradas e, portanto, a chance de encontrar a solução ótima do problema também aumenta. Nota-se, entretanto, que o tempo de execução aumenta proporcionalmente com o coeficiente α , torando-se da ordem de segundos em determinado momento, fator que é indesejado, principalmente ao mirar a escalabilidade da metaheurística com o custo aumentado ao trabalhar com problemas maiores e mais complexos.

Por fim, pode-se observar a eficácia da metaheurística, tendo em vista que a solução obtida é ótima e igual à encontrada em ambos os métodos explicitados anteriormente, em relação ao valor do custo final.

4 CONCLUSÃO

Frente ao exposto ao longo do presente trabalho, esta seção é dedicada, primordialmente, ao comparativo entre todos os resultados obtidos.

A Tabela 13 apresenta indicadores computacionais adicionais referentes aos *solvers* exatos. Verifica-se que ambos alcançaram a mesma solução ótima, com *gap* de otimalidade nulo, porém com diferenças no esforço computacional empregado durante o processo de resolução.

Tabela 13: Indicadores computacionais dos *solvers* exatos.

Indicador	Gurobi	SCIP
Valor da função objetivo	97	97
<i>Gap</i> de otimalidade (%)	0	0
Nós explorados na árvore <i>B-B</i>	4125	4744
Variáveis do modelo	1960	1960
Restrições do modelo	5887	3217
Tempo de execução (s)	1,57	246

Fonte: Dos próprios autores.

Além disso, a Tabela 14 apresenta uma comparação geral entre as abordagens empregadas. Observa-se que tanto os *solvers* exatos quanto a metaheurística foram capazes de encontrar soluções com o mesmo valor de função objetivo para a instância considerada, evidenciando a consistência dos resultados obtidos.

Tabela 14: Comparação entre as abordagens utilizadas.

Método	Resultado	Custo Final	Tempo (s)
Gurobi	Solução ótima	97	1,57
SCIP	Solução ótima	97	246
SA	Melhor solução encontrada	97	7,63

Fonte: Dos próprios autores.

Do ponto de vista prático, a aplicação desenvolvida demonstra como técnicas de otimização podem auxiliar instituições de ensino na elaboração de calendários de avaliações mais equilibrados e menos desgastantes para os estudantes. A utilização de modelos matemáticos permite automatizar um processo tradicionalmente complexo, reduzindo conflitos e melhorando a qualidade da programação acadêmica.

Como possíveis perspectivas para trabalhos futuros, podem ser incorporadas novas restrições ao modelo, como limitações de capacidade de salas, indisponibilidade de docentes, distribuição equilibrada de avaliações ao longo da semana e, inclusive, preferências institucionais específicas. Também podem ser investigadas abordagens híbridas, combinando métodos exatos e metaheurísticas, visando obter soluções de alta qualidade para instâncias de maior porte.

Em suma, o desenvolvimento deste projeto proporcionou uma compreensão mais aprofundada dos conceitos de **Programação Linear Inteira**, modelagem matemática e métodos de otimização. Além disso, foi possível compreender os desafios envolvidos na transformação de um problema real em um modelo computacionalmente tratável, bem como a importância da análise crítica dos resultados obtidos por diferentes abordagens de solução.

REFERÊNCIAS BIBLIOGRÁFICAS

BURKE, E. K.; PETROVIC, S. Recent research directions in automated timetabling. *European Journal of Operational Research*, 2002.

CARTER, M. W.; LAPORTE, G. Recent developments in practical examination timetabling. *Lecture Notes in Computer Science*, 1996.